Высшая
школа
бизнеса

Конференция
Научный телеграф

Москва
Май 2026

Автоматическая эволюция LLM-агентов через рефлексивное редактирование контекста

Автор: Глеб Дементьев, НИУ ВШЭ
Руководитель: Сеунгмин Джин, PhD, НИУ ВШЭ

Ключевые понятия

Большая языковая модель

Нейросеть, генерирующая текст на основе выученных распределений

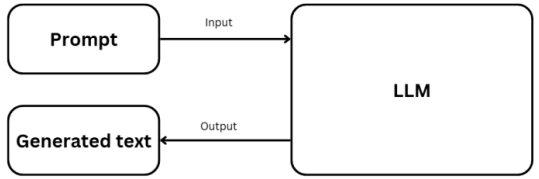

GPT-5.4, Opus 4.6, Gemini 3.1

Агент с вызовом инструментов

LLM-обвязка для вызова внешних инструментов через структурированный вывод

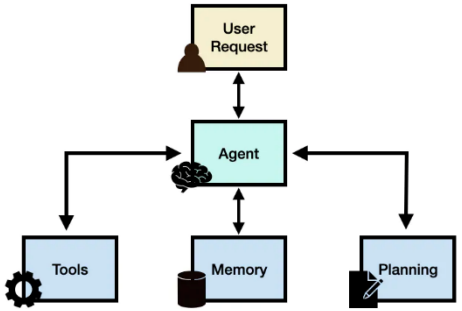

Claude Code, OpenAI Codex, Manus

Агентный бенчмарк

Производительность LLM на задачах с планированием и действием

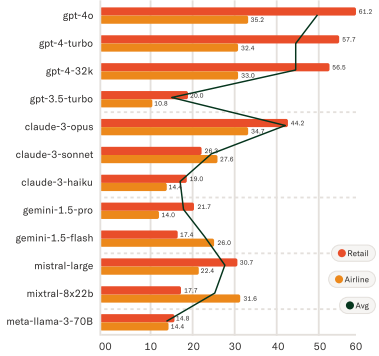

Tau-2, Toolbench, GAIA

Эволюция промптов

Автоматический рост pass-rate бенчмарка

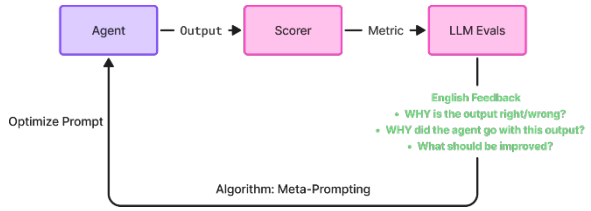

GEPA, DSPy, EvoPrompt

Внедрение агентов упирается в команду внедрения

В моей компании 75 FTE

Выручка моего продукта 200 млн ₽

ФОТ внедрения составляет 37% выручки

= 37% выручки

Каждое новое внедрение нагружает ту же команду из 25 человек. Структура затрат линейна по числу внедрений.

Проблема: LLM-агенты ненадежны в энтерпрайзе

Цель: автоматически улучшать агентов и исправлять ошибки

Задача	Результат
Базово оценить % прохождения на τ^2-bench airline	Список проблем
Предложить механизм улучшения % прохождения	Фреймворк эволюции промтов
Оценить на 5/10/20 задачах и 3 моделей	Оценка применимости к моделям и масштабируемости
Проанализировать успешность патчей	Оценка границ вмешательства на уровне промта

Обзор литературы: зачем эволюция на уровне промптов?

1. Агенты не справляются

LLM-агенты значительно ниже корпоративных порогов надёжности

tau-bench (Yao и др., 2024)
GPT-4o проваливает >50% задач

GAIA (Mialon и др., 2023)
люди 92% против GPT-4 15%

SWE-bench (Jimenez и др., 2024)
лучшая модель решает <2%

ToolBench (Qin и др., 2023)
OSS-модели набирают 0%

Агентам нужно быть лучше. Можно ли обойтись промпт-инжинирингом?

2. Промптинг хрупок

Статичные промпты помогают, но хрупки и упираются в потолок

Чувствительность (Sclar и др., 2023)
формат → разброс 76 п.п.

CoT (Wei и др., 2022)
слишком долго

ReAct (Yao и др., 2023)
прирост есть, нет самовосстановления

APE (Zhou и др., 2022)
оптимальные промпты хрупки

Ручные промпты не адаптируются. Может, тогда дообучать?

3. Дообучение дорого

Модификация весов работает, но есть трейдоффы и ненадежности

Alignment tax(Young, 2026)
доказана неустранимость

Вред от SFT (Shenfeld, 2026)
разрушает рассуждение

LIMA (Zhou и др., 2023)
выравнивание = стиль, а не знание

InstructGPT (Ouyang и др., 2022)
1,3 млрд > 175 млрд, но регрессирует

Веса — не тот уровень. Можно ли оптимизировать промпты автоматически?

4. Автооптимизация

Оптимизаторы промптов дают прирост — но не на агентах

DSPy (Khattab и др., 2023)
+5–46% на HotPotQA

TextGrad (Yuksekgonul, 2024)
+20% LeetCode; Nature

EvoPrompt (Guo и др., 2023)
+25% Big-Bench Hard

OPRO (Yang и др., 2023)
+50% Big-Bench Hard

Инструменты есть, бенчмарки есть, но они ещё не встретились.

Модели: open-source SOTA (для локального развертывания)

Роль	Модель	Обоснование
Ученик	Qwen3 30B-A3B	Экономичная MoE; запас до фронтира, non-thinking
Ученик	Qwen3.5 Flash	SOTA Qwen на момент выбора, non-thinking
Ученик	GLM 4.7 Flash	Другая архитектура, сопоставимые бенчмарки, non-thinking
Учитель	Kimi K2.5 (~1T MoE)	OSS фронтир на момент исследования, thinking

Датасет: отраслевой бенчмарк-стандарт

τ^2-bench (2025): агенты автоматизации клиентского сервиса с готовыми промптами, без насыщения, с вызовом инструментов и сложными режимами отказа

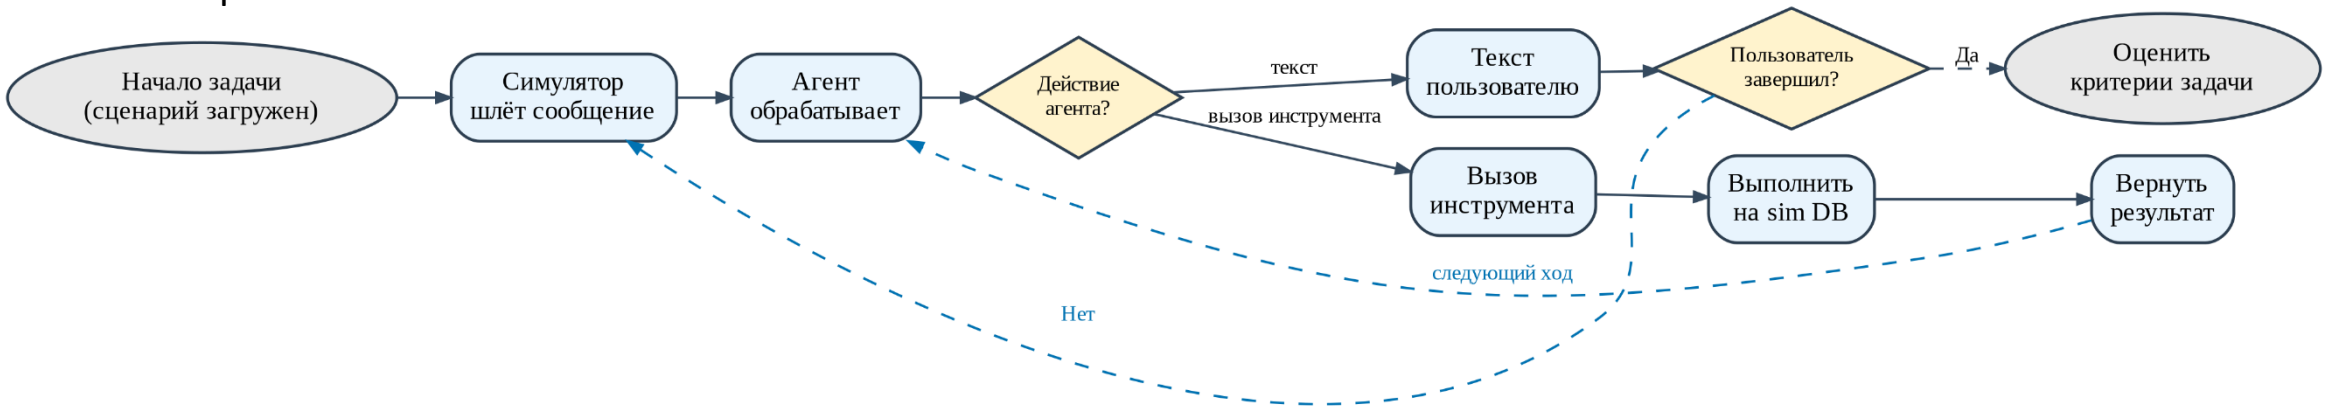

Учитель находит и исправляет ошибки, сливая правки в общий промпт

1. Запуск бенчмарка → 2. Поиск ошибок → 3. Попытка исправить каждую ошибку → 4. Объединение исправлений → 5. Повторный запуск бенчмарка

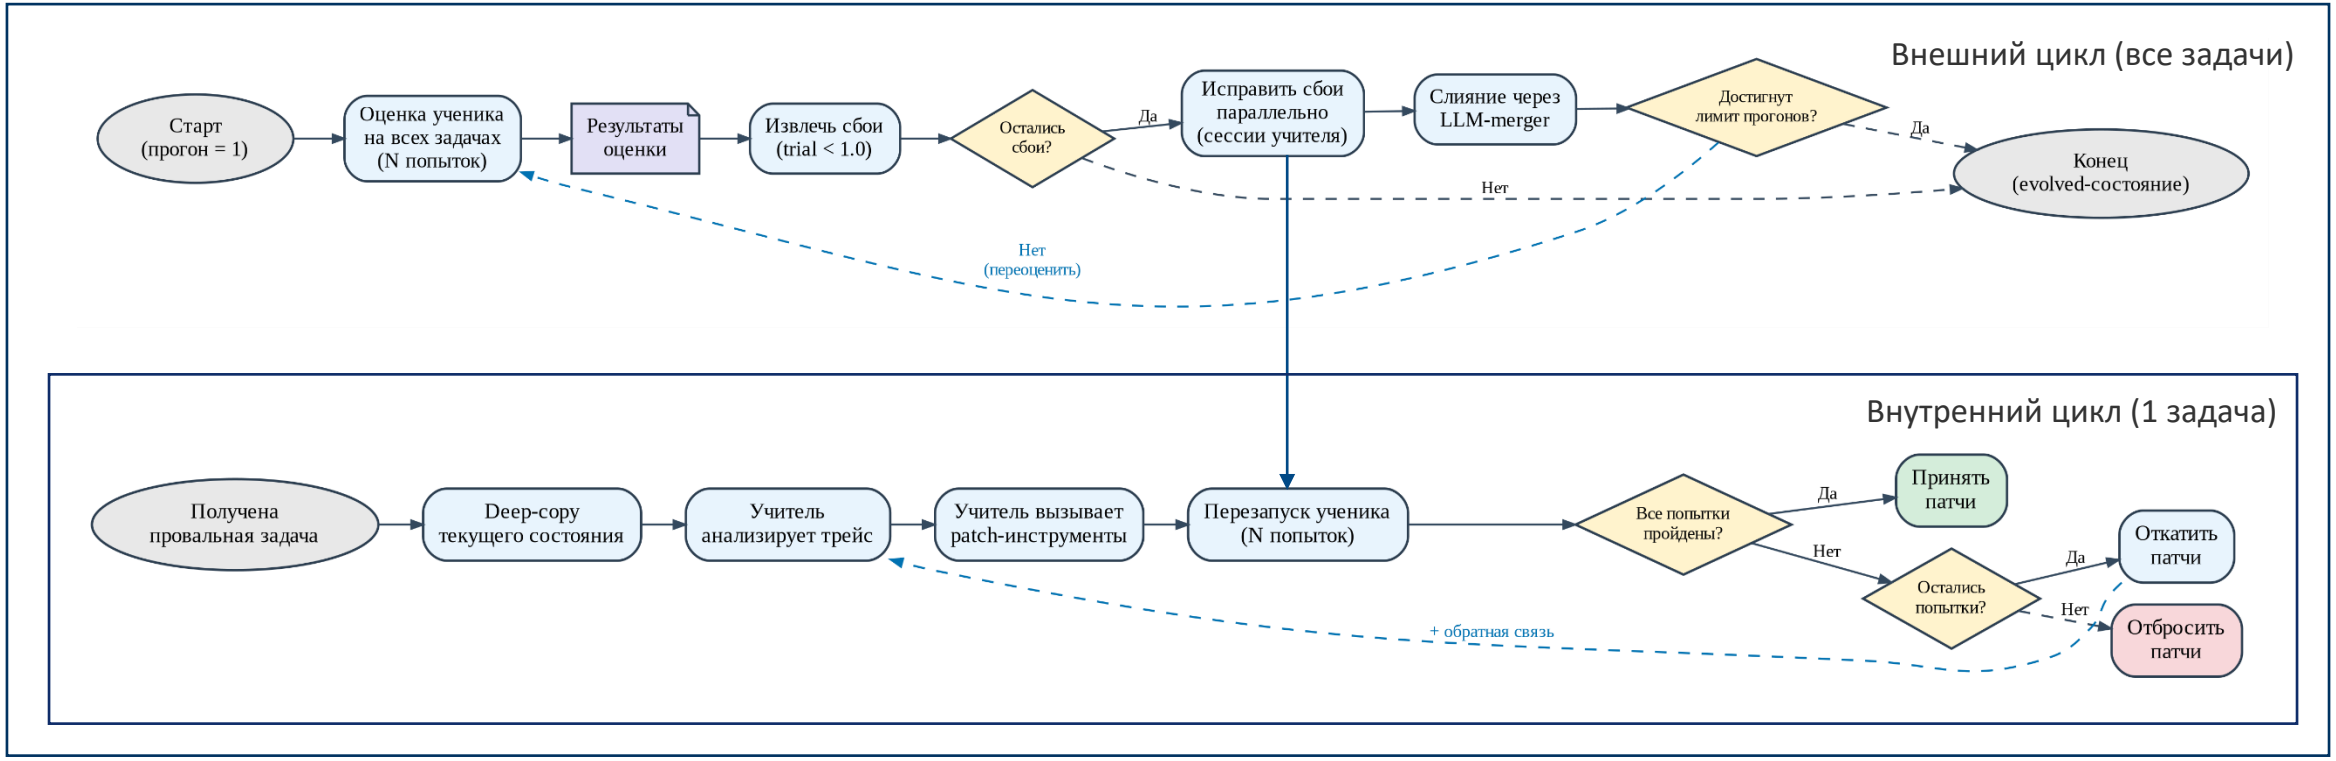

Учитель правит промпт, инструменты и валидаторы

1. Бенчмарк оценивает задачу
2. Бенчмарк классифицирует ошибку
3. Бенчмарк передаёт Учителю ошибку и ее причину
4. Учитель вызывает инструменты для модификации Ученика
5. Патчи которые помогли, применяются
6. Пропатченный Ученик тестируется

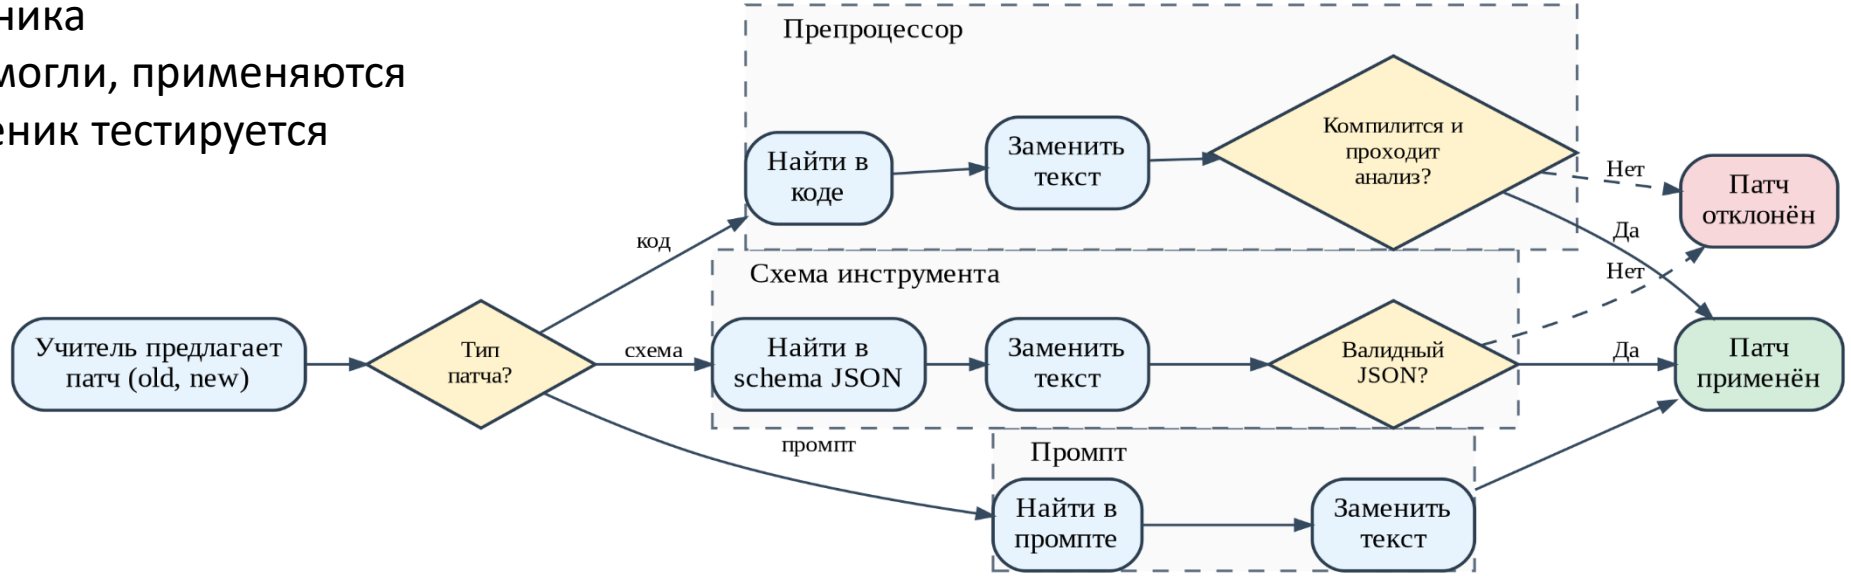

Экспериментальный интерфейс

Сводка прогона на 20 задачах

SWEEP RESULTS Per-task fix attempts across sweeps

#	TASK	BASE	PATCH	DELTA	STATUS	TIER	TRY	MSGS	CALLS
1	7	Fail	Fail	0→0	NOT FIXED	—	—	26	10
1	11	Fail	Fail	0→0	NOT FIXED	—	—	56	24
1	10	Fail	Pass	0→1	FIXED	instruction	2	18	7
1	5	Fail	Fail	0→0	NOT FIXED	—	—	44	18
1	1	Fail	Pass	0→1	FIXED	guardrail	3	18	6
1	12	Fail	Fail	0→0	NOT FIXED	—	—	56	24
1	9	Fail	Fail	0→0	NOT FIXED	—	—	54	21
2	4	Fail	Pass	0→1	FIXED	instruction	1	8	3
2	1	Fail	Pass	0→1	FIXED	instruction	1	13	5
2	7	Fail	Fail	0→0	NOT FIXED	—	—	45	20
2	12	Fail	Fail	0→0	NOT FIXED	—	—	71	30
2	11	Fail	Fail	0→0	NOT FIXED	—	—	43	19
2	10	Fail	Fail	0→0	NOT FIXED	—	—	45	20

LLM-учитель генерирует исправление

```
Let me fix this by adding clear instructions to the system prompt about the proper workflow for modifying flights.

TOOL CALL patch_prompt functions.patch_prompt:0
{
  "old_text": "## Modify flight\n\nFirst, the agent must obtain the user id and reservation id. \n- The user must provide their user id. \n- If the user doesn't know their reservation id, the agent should help locate it using available tools.",
  "new_text": "## Modify flight\n\nFirst, the agent must obtain the user id and reservation id. \n- The user must provide their user id. \n- If the user doesn't know their reservation id, the agent should help locate it using available tools.\n\n**Workflow for modifying flights:**\n1. Retrieve the user's details to get
```

Карта результатов: 20 задач × 3 прогона

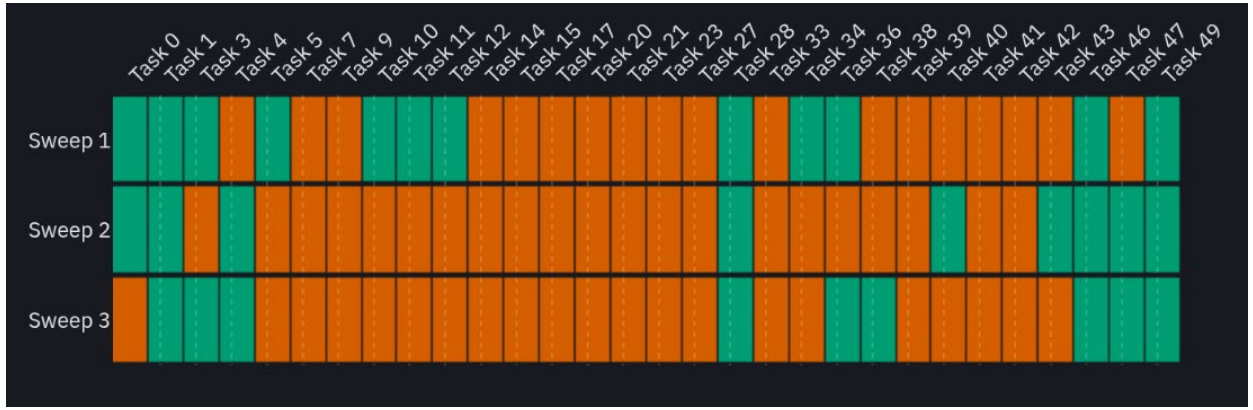

Большинство моделей показали рост успешности

Модель →	Qwen 30		Qwen 3.5		GLM-4.7	
Кол-во задач	До	После	До	После	До	После
5	53%	73%	100%	100%	47%	47%
10	27%	50%	60%	63%	50%	40%
20	22%	30%	47%	58%		

Часть задач исправляется автоматически; другие устойчивы

	Qwen3 30B-A3B		Qwen3.5 Flash		GLM 4.7 Flash	
Задача	База	Эволюц.	База	Эволюц.	База	Эволюц.
0	1/3	3/3	3/3	3/3	3/3	2/3
1	2/3	2/3	3/3	3/3	2/3	2/3
3	0/3	0/3	3/3	3/3	3/3	2/3
4	3/3	2/3	3/3	3/3	3/3	2/3
5	2/3	3/3	2/3	3/3	2/3	1/3
7	0/3	0/3	0/3	0/3	0/3	0/3
9	0/3	0/3	0/3	0/3	0/3	0/3
10	2/3	1/3	3/3	3/3	2/3	2/3
11	1/3	0/3	1/3	2/3	0/3	1/3
12	0/3	0/3	0/3	3/3	0/3	0/3
14	0/3	0/3	0/3	0/3	N/A	N/A
15	0/3	1/3	1/3	1/3	N/A	N/A
17	0/3	0/3	2/3	3/3	N/A	N/A
20	0/3	0/3	2/3	2/3	N/A	N/A
21	0/3	0/3	1/3	2/3	N/A	N/A
23	0/3	0/3	0/3	0/3	N/A	N/A
27	0/3	0/3	0/3	3/3	N/A	N/A
28	0/3	3/3	3/3	3/3	N/A	N/A
33	0/3	1/3	0/3	0/3	N/A	N/A
34	2/3	2/3	1/3	1/3	N/A	N/A

1. Многие задачи полностью устойчивы к модификации промпта: мы упёрлись в потолок рассуждательных способностей модели
2. Большая часть исправлений достигается через инструкцию

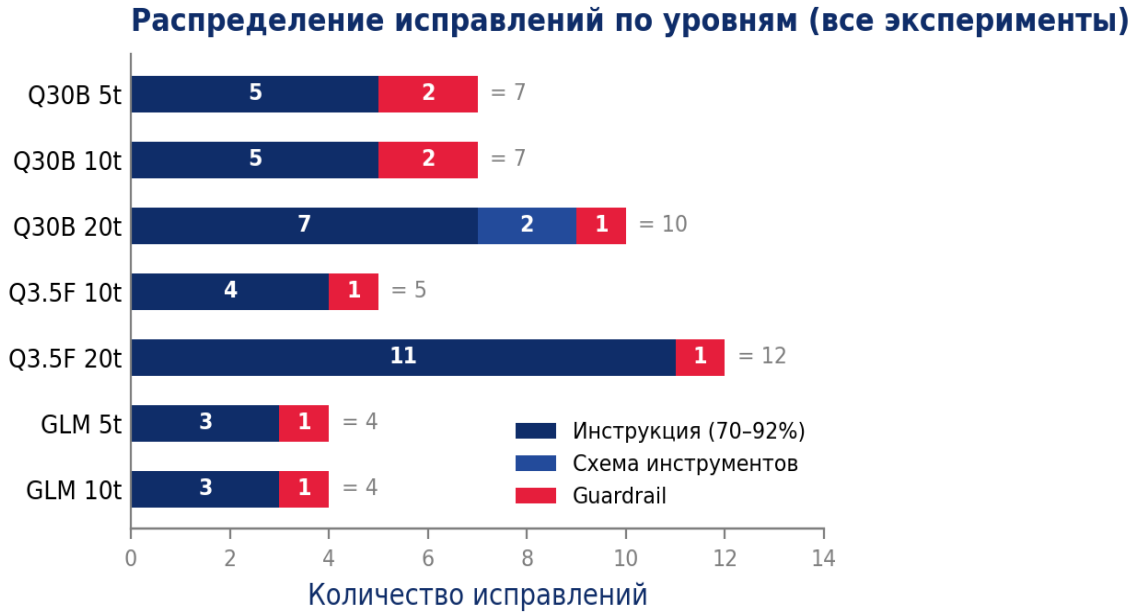

Чем больше задач, тем ниже доля исправлений

1. Некоторые модели вообще не получают пользы от настройки промптов — например, GLM 4.7
2. Все модели плохо удерживают прирост: в прогоне 1 доля исправлений 100%, к прогону 3 сохраняется лишь половина
3. Чем сильнее модель, тем больше удерживает → Qwen 3.5 превосходит Qwen 3

5 задач | 10 задач | 20 задач

Qwen 3

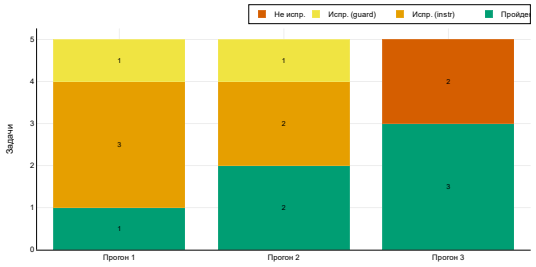

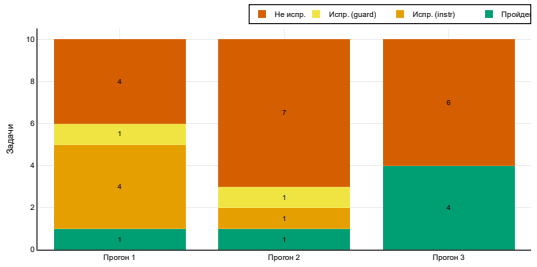

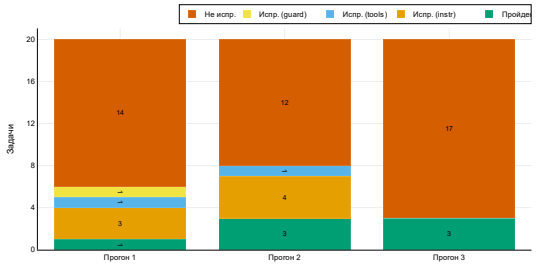

Qwen 3.5

Исправлять нечего; всё зелёное

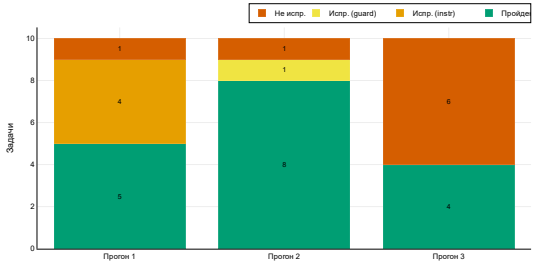

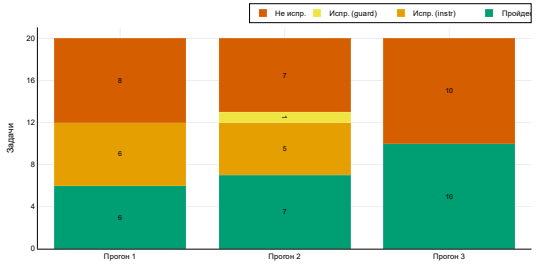

GLM 4.7

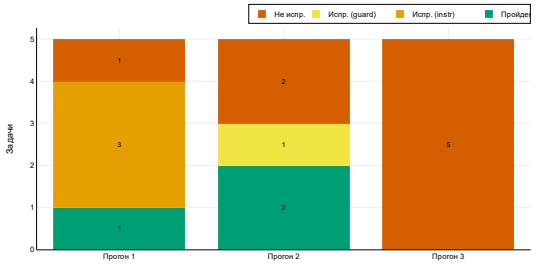

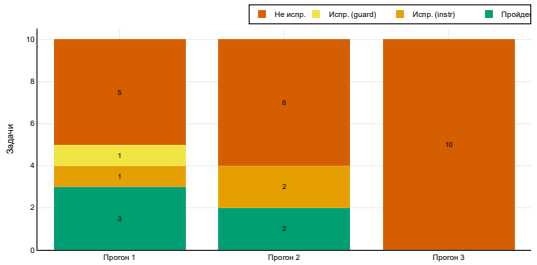

Не тестировалось из-за продолжающейся регрессии

1 **Автоматическая эволюция промтов работает на агентском бенчмарке**

2 **Не все модели получают прирост результата, некоторым сложнее следовать инструкциям. Есть какой-то трешхолд.**

3 **Чем больше задач оптимизируем одновременно, тем ниже прирост. Нужна декомпозиция.**

4 **Существуют не поддающиеся улучшению задачи, сколько бы мы ни пытались.**

Недостатки

- Тестировался один домен; всего 20 задач × 3 попытки
- Только open-source модели
- Нет сравнений с RLHF, LoRA
- Недостаточная надёжность: 73% << 99,99%

Дальнейшие шаги

- Варьировать учителей и учеников
- Сравнить с адаптированным GEPA
- Многоагентная декомпозиция
- Проверить на других бенчмарках

@GLEBDEMENTEV

Глеб Дементьев

НИУ ВШЭ
gddementev@mail.ru
@glebdementev